Kaggle Competition

ML Competition



10조 김영호 김해나 서동민 장승혁

목차



01. 데이터 탐색

02. EDA

03. Feature Engineering

04. Modeling

05. 평가 및 보완점

Bank Marketing

1. 데이터 탐색
2. EDA
3. Feature Engineering
4. Modeling
5. 평가 및 보완점

Bank Marketing - 정기예금 가입 여부 예측



은행이 가진 고객 정보





고객 가입 여부 예측

Bank Marketing

1. 데이터 탐색

2. EDA

3. Feature Engineering

4. Modeling

5. 평가 및 보완점

▪ Data Overview

범주형 변수

9개

'job', 'marital', 'education', 'default', 'housing', 'loan', 'contact', 'month', 'poutcome'

수치형 변수

7개

'age', 'balance', 'day', 'duration', 'campaign', 'pdays', 'previous'

Y(label)

불균형

비율

0 : 0.883022

1 : 0.116978



Bank Marketing

1. 데이터 탐색

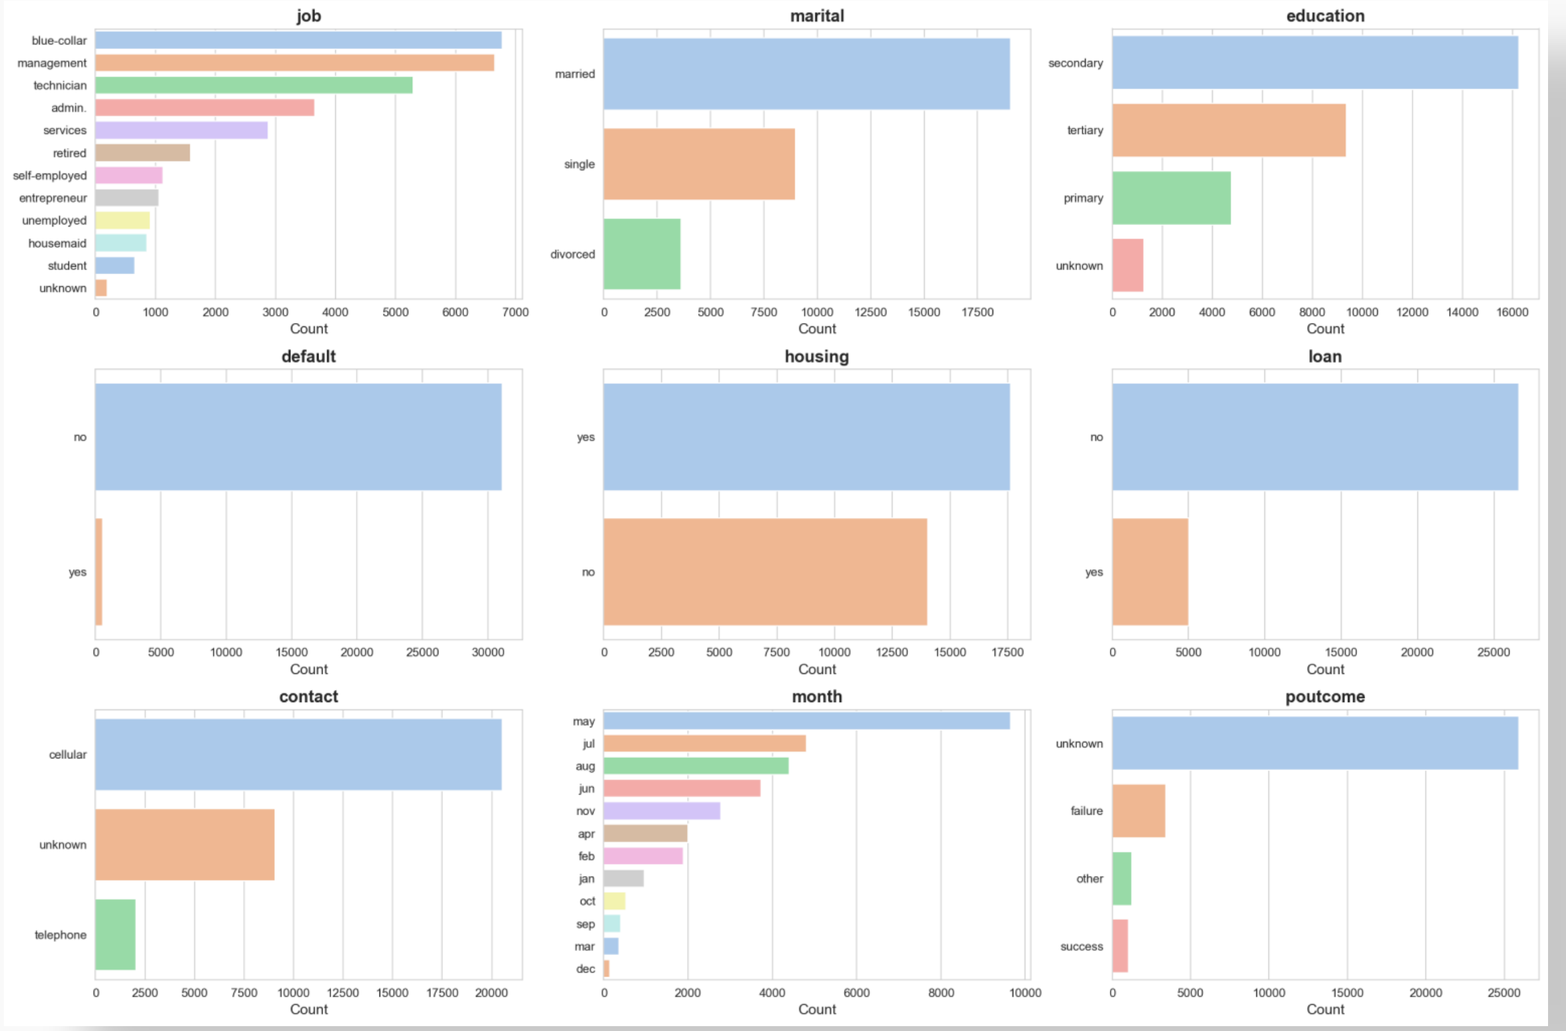
2. EDA

3. Feature Engineering

4. Modeling

5. 평가 및 보완점

▪ 범주형 변수



Bank Marketing

1. 데이터 탐색

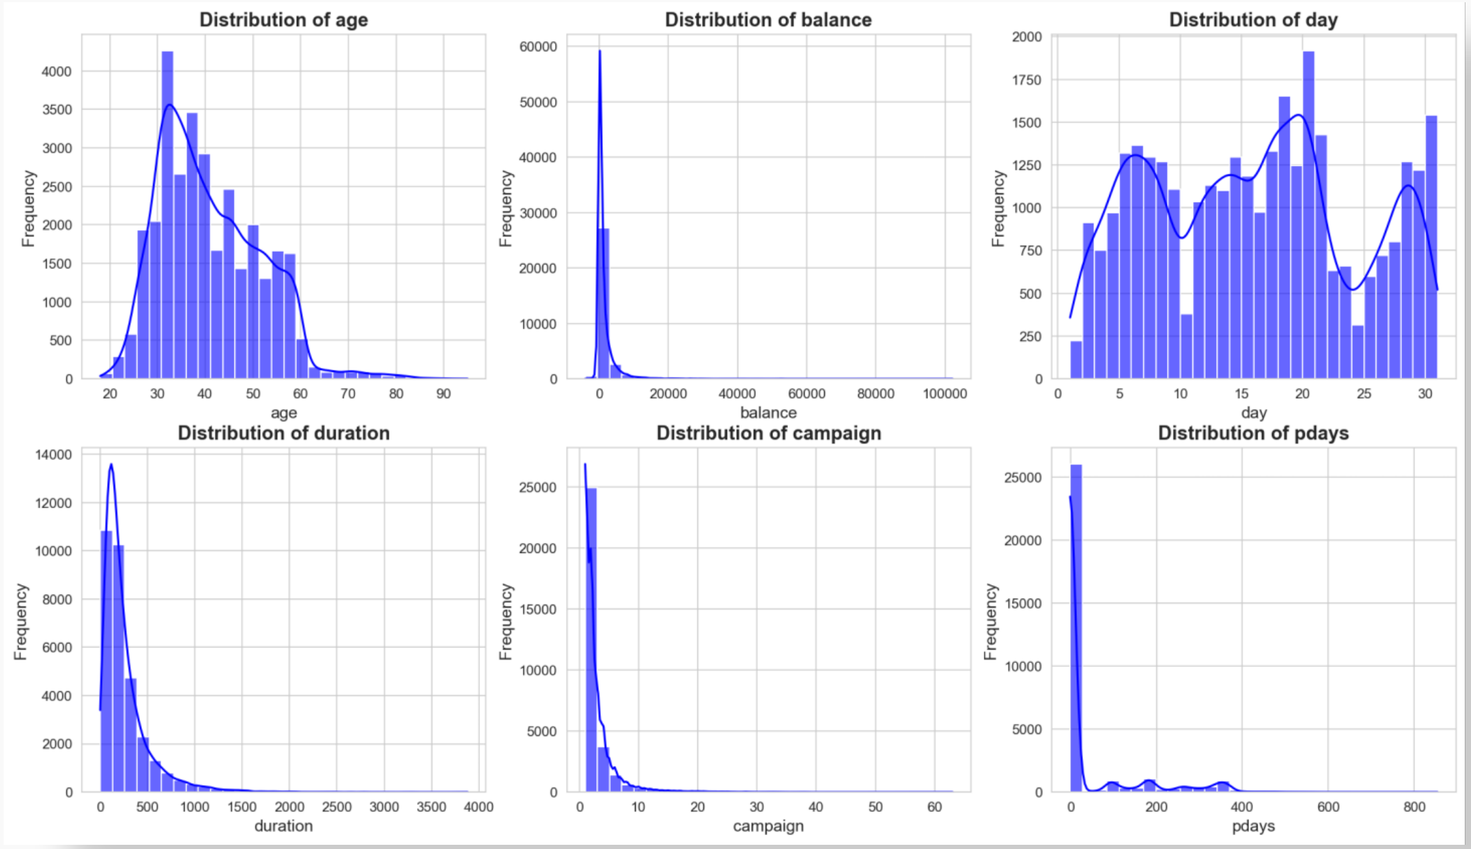
2. EDA

3. Feature Engineering

4. Modeling

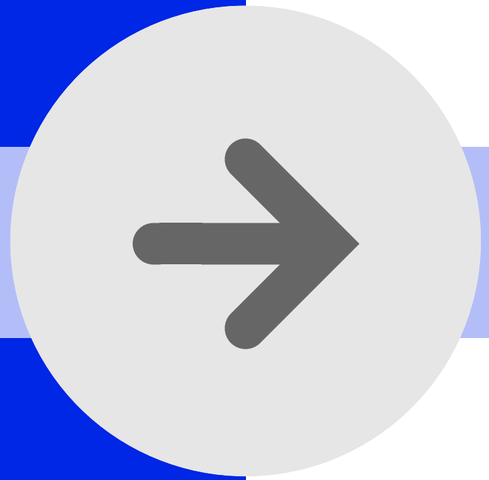
5. 평가 및 보완점

▪ 수치형 변수



모델링 방식

개별적으로
모델링 진행



f1 스코어
비교 후 모델 결정

팀원 개별적으로
전처리부터 모델링까지 진행

회의 때 각자의 모델에 대해 설명하고,
f1 스코어 비교 후 전처리 / 모델 결정

Bank Marketing

1. 데이터 탐색

2. EDA

3. Data Processing

4. Modeling

5. 평가 및 보완점

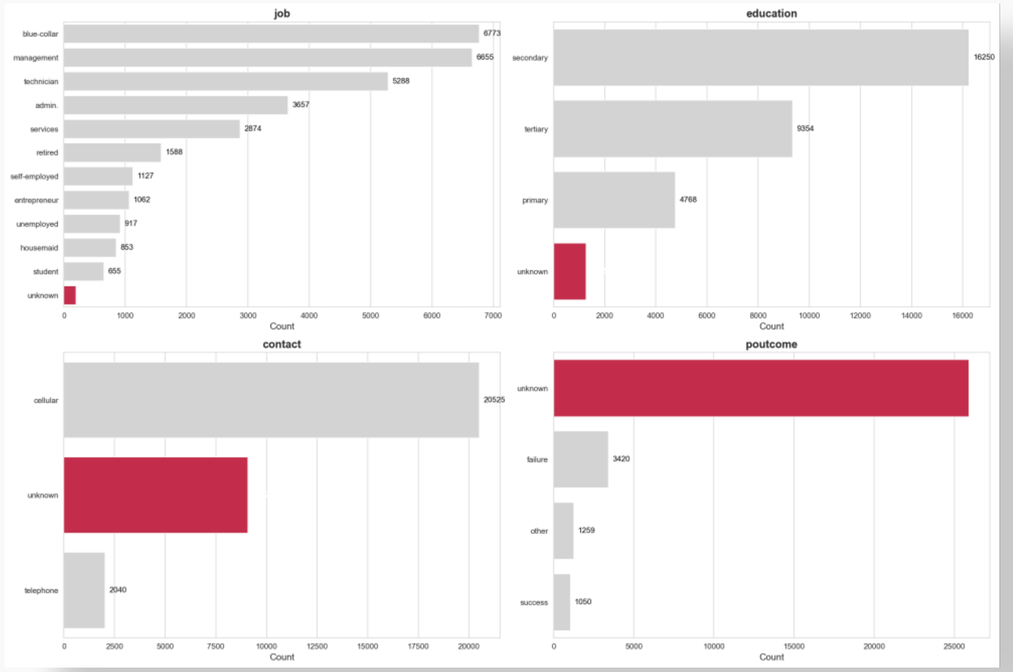
▪ 결측치 처리

- 결측치는 0

```
df.isnull().sum()
✓ 0.0s

ID          0
age         0
job         0
marital     0
education   0
default     0
balance     0
housing     0
loan        0
contact     0
day         0
month       0
duration    0
campaign    0
pdays       0
previous    0
poutcome    0
label       0
dtype: int64
```

- Unknown



→ 범주형 변수들을 결합 (e.g. job-education)한 **라벨 인코딩**으로 처리
결과적으로 모델이 단순한 조합으로만 기억해, **과적합 발생**
unknown 도 하나의 고윳값으로 처리

Bank Marketing

1. 데이터 탐색

2. EDA

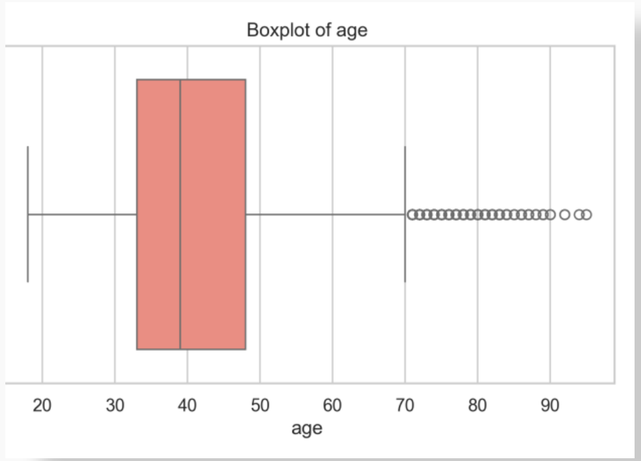
3. Data Processing

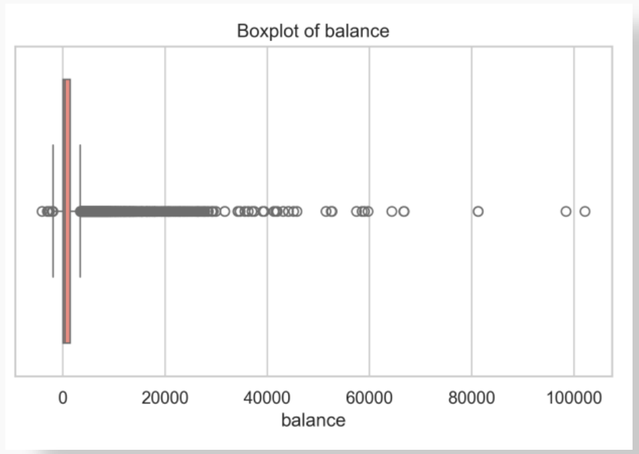
4. Modeling

5. 평가 및 보완점

▪ 이상치 처리

- IQR 방식으로 진행 (Q3 - Q1)





관련된 변수들을 '**이상치**' 라고 판단할 근거 부족

다른 수치형 변수들의 경우 scaling 진행시 성능하락

→ 이상치 처리 / scaling 사용하지 않는 것으로 결정

Bank Marketing

1. 데이터 탐색

2. EDA

3. Feature Engineering

4. Modeling

5. 평가 및 보완점

▪ 범주형 변수

```
# 범주형 데이터를 라벨 인코딩
cat = ['job','marital','contact','poutcome','education','default','housing','loan','month']
label_encoder = {}
for col in cat:
    le = LabelEncoder()
    df_trn[col] = le.fit_transform(df_trn[col])
    df_tst[col] = le.transform(df_tst[col])
    label_encoder[col] = le
```

- 라벨 인코딩 진행
- 원핫 인코딩도 진행해봤으나 feature 개수가 많아져 과적합 발생

Bank Marketing

1. 데이터 탐색

2. EDA

3. Feature Engineering

4. Modeling

5. 평가 및 보완점

▪ 파생변수

이전 연락이력(pdays_contacted)

기존 pdays가 -1이 아닌 경우(즉, 과거 캠페인에서 이 고객에게 연락한 적이 있으면) 1 아니면 0
고객이 이전에 마케팅 연락을 받은 적이 있는지 **이진 정보**로 단순화

평균 통화 시간/빈도(duration_per_campaign)

duration(통화 길이)를 campaign+1(연락 횟수+1)로 나눈 값
고객에게 연락할 때마다 **평균적으로 얼마나 오래 통화**했는지 알기 위함

연속된 날짜/타이밍(day_of_year)

월과 일을 결합해 1년 중 어느 날에 가까운지 계산한 값 (day + (month-1)*30)
대략적 **시점**을 표현

계절(season)

월에 따라 봄, 여름, 가을, 겨울로 계절 변환 그리고 라벨링 진행

Bank Marketing

1. 데이터 탐색
2. EDA
3. **Feature Engineering**
4. Modeling
5. 평가 및 보완점

▪ Feature Selection

```python
# 변수 선택 모델 정의
sfs = SequentialFeatureSelector(
    base_model,
    n_features_to_select='auto',
    direction='forward',
    scoring='f1',
    cv=5,
    n_jobs=-1
)
# 변수 선택 모델 학습하기
sfs.fit(df_retrn_x, df_retrn_y)
```

- 가장 성능이 좋았던 lgbm을 base model 로 설정
- 최적의 하이퍼 파라미터 수를 모르기 때문에 auto 로 설정을 진행
- 계산 복잡도로 인해 전진선택법을 진행
  후에 후진선택법도 진행해봤으나 전진선택법의 성능이 더 좋았음
- 5- fold 교차 검증을 진행해 f1 스코어를 기반한 변수 선택 진행



'age', 'housing', 'contact', 'day', 'duration', 'campaign', 'pdays', 'poutcome', 'duration_per_campaign', 'day_of_year'

Bank Marketing

1. 데이터 탐색

2. EDA

3. Feature Engineering

4. **Modeling**

5. 평가 및 보완점

▪ 전체 Modeling 과정



- XGBoost, LGBM, CatBoost, GBM 등 다양한 분류 모델을 모델링해본 결과 LGBM의 성능이 가장 높은 것을 확인
- 이후 Random Search 로 성능이 좋았던 점을 감안해 **Grid Search로** 하이퍼파라미터 튜닝
- 최적의 Threshold 값을 찾아 재학습

Bank Marketing

1. 데이터 탐색

2. EDA

3. Feature Engineering

4. **Modeling**

5. 평가 및 보완점

▪ 파라미터 설정

```
# 파라미터 리스트 설정
param_grid = {
    'learning_rate': [0.1,0.15,0.2],
    'n_estimators': [300,400,500],
    'max_depth': [3,4,5],
    'min_child_samples': [50, 100, 150],
    'subsample': [0.7,0.8,0.9],
    'colsample_bytree': [0.6,0.7,0.8],
    'class_weight': ['balanced']
}
```

- 리프 노드 최소 샘플 수(min_child_samples)
  - 리프노드가 되기 위해 필요한 최소 샘플 수
- 데이터 샘플링 비율(subsample)
  - 훈련 데이터를 일정 비율만 사용
- feature 비율(colsample_bytree)
  - 전체 feature 중 일부 비율만 사용
  - 트리의 다양성 & 모델의 안정성
- 클래스별 가중치 (class_weight)
  - 불균형 데이터를 위한 가중치
  - **각 클래스 빈도 역수 비율**만큼 가중치 적용

최적 하이퍼파라미터: {'class_weight': 'balanced', 'colsample_bytree': 0.6, 'learning_rate': 0.15, 'max_depth': 5, 'min_child_samples': 150, 'n_estimators': 500, 'subsample': 0.7}

Bank Marketing

1. 데이터 탐색

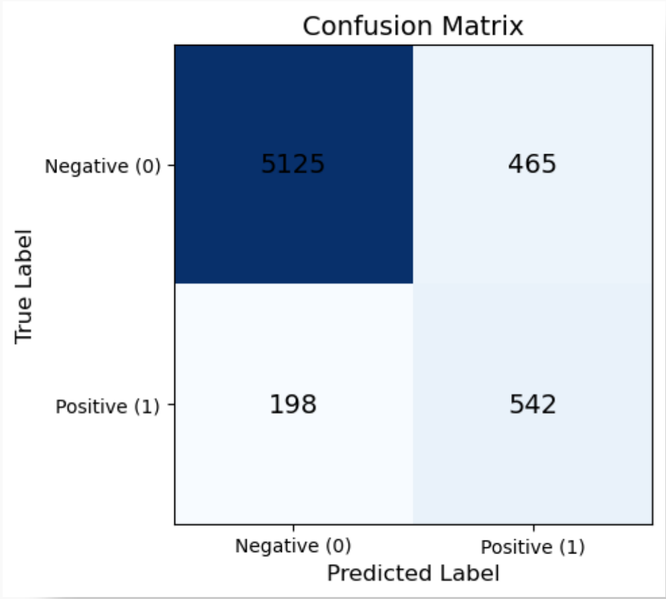
2. EDA

3. Feature Engineering

4. Modeling

5. **평가 및 보완점**

▪ 평가



훈련 데이터

Accuracy: 0.9304
Precision: 0.6480
Recall: 0.8872
F1 Score: 0.7490

검증 데이터

Accuracy: 0.8952
Precision: 0.5382
Recall: 0.7324
F1 Score: 0.6205

Leader Board (f1 score)

0.66178 → 0.63143

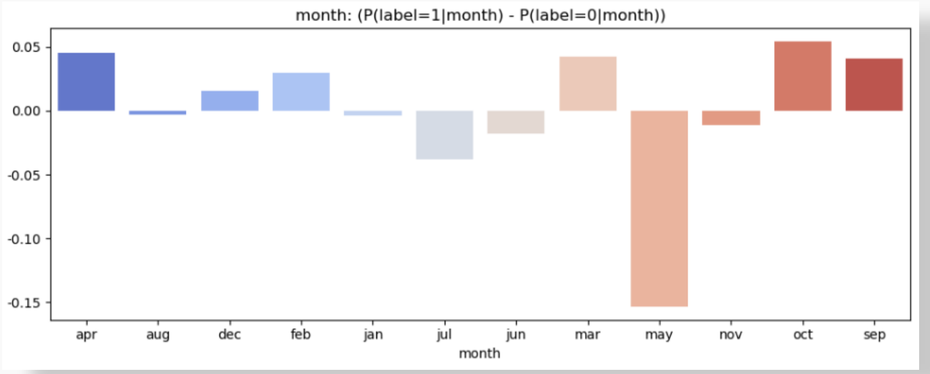
INSIGHT

학습 후 feature importances

Feature	Importance
day_of_year	1646
duration	1246
duration_per_campaign	1147
age	1014
day	739
pdays	724
campaign	341
housing	163
poutcome	145
contact	139

day_of_year , day, pdays

"특정 시점"에 마케팅을 진행하는 것이 성공률을 높임



- P(label = 1 | month) - P(label = 0 | month)
  월별로 (그 달에 연락받은 고객 중 실제로 가입한 비율) - (가입하지 않은 비율)

- 5월은 데이터 수가 많으나, 5월에 연락된 고객은 가입보다 비가입 성향이 매우 큼.
  (가입 확률이 미가입 확률보다 약 15%p 낮음)

- 10월, 4월, 9월달에 특정 시점을 찾아 연락을 하는 것이 정기예금 가입확률을 높임

INSIGHT

학습 후 feature importances

Feature	Importance
day_of_year	1646
duration	1246
duration_per_campaign	1147
age	1014
day	739
pdays	724
campaign	341
housing	163
poutcome	145
contact	139

duration / duration_per_campaign

- 통화시간이 길수록 가입확률이 높아짐
- 단순히 통화시간이 긴 것도 중요하지만, 시도 횟수 대비 전화 시간에 대한 고려도 필요

age

- 연령대에 대한 고려 필요

통합적 마케팅 전략

- 특정 시점에 따른 마케팅 전략 필요 - 시점별 프로모션
- 통화시간을 고려한 교육 필요 - 횟수별 통화시간에 따라 상담자 응대 메뉴얼 실행
- 특정 연령대가 반응할 수 있는 마케팅 전략 필요 (e.g. 3-40대 - 주택예금 가입권유)

Bank Marketing

1. 데이터 탐색

2. EDA

3. Feature Engineering

4. Modeling

5. **평가 및 보완점**

▪ 아쉬운 점(보완점)

1 Ensemble 미사용

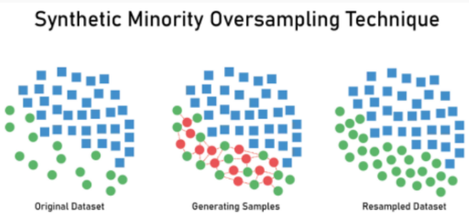
- 최종 모델이 오직 LGBM 한 가지만 반영됨
  → LGBM 고유의 편향이나 과적합 리스크를 분산시키지 못함

- 앙상블 사용했다면 과적합 완화, 모델 분산 감소에 효과적

2 불균형 데이터 처리방법

- 불균형 데이터 처리할 때, class_weight='balanced'만 사용
  다른 기법들도 사용해 봤으면 F1 score 향상에 많은 도움을 줬을 것으로 예상

SMOTE : 소수 클래스의 샘플을 합성하여 데이터셋을 균형있게 만드는 방법



Bank Marketing

1. 데이터 탐색

2. EDA

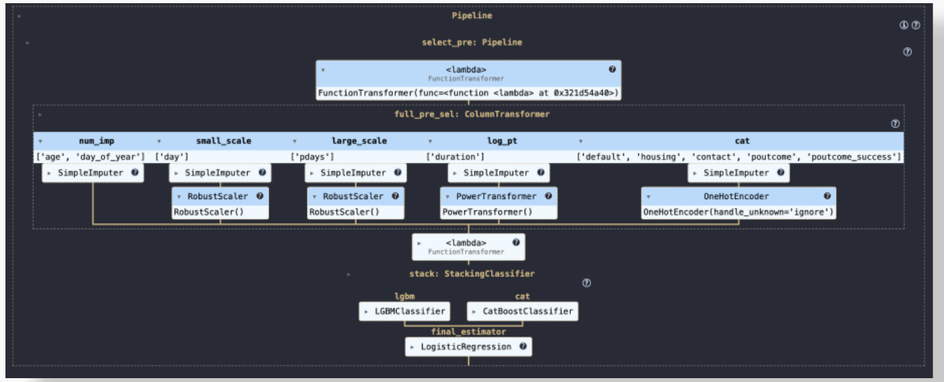
3. Feature Engineering

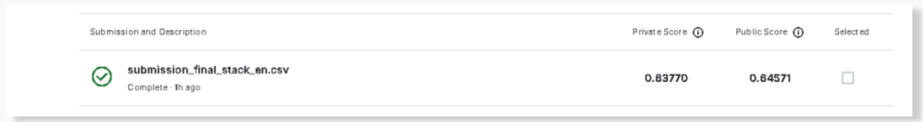
4. Modeling

5. **평가 및 보완점**

▪ 아쉬운 점(보완점)

3 Submission 하지 못한 모델





- 전처리 방식 (Sequential Feature Selection)
  - 수치형 변수 robust scaler
  - duration의 경우 power transformer
  - 범주형 변수 one-hot encoding
- Optuna 를 통해 하이퍼 파라미터 튜닝
- Stacking Classifier
  - LGBM, CatBoost + LR

10조
김영호 김해나 서동민 장승혁

감사합니다.